

Rapport de Projet

Année universitaire 2025–2026

Résumé

La sécurité des usagers de la route vulnérables (piétons, cyclistes, motocyclistes) constitue un enjeu majeur dans les réseaux de communication véhiculaires modernes. Ces usagers peuvent être détectés par des capteurs GPS et des systèmes V2X, permettant de calculer leur proximité dangereuse avec des véhicules à moteur et de déclencher des alertes en temps réel. Cependant, les décisions de communication – transmettre directement de véhicule à véhicule (V2V) ou transiter par une infrastructure (V2I) via une unité de bord de route (RSU) – sont aujourd’hui prises de manière statique, sans adaptation aux conditions du réseau. Ce rapport propose un mécanisme de sélection adaptatif du mode de communication fondé sur l’approche *Multi-Armed Bandit* (MAB). Deux algorithmes sont mis en œuvre et comparés : la politique ε -greedy et la politique UCB (*Upper Confidence Bound*). Les critères de décision comprennent le délai de transmission, le taux de perte de paquets et la charge réseau. Les résultats obtenus par simulation montrent que l’approche MAB permet une sélection dynamique et efficace du mode de communication, en s’adaptant aux conditions du réseau et au type d’utilisateur (piéton, motocycliste, véhicule), tout en minimisant la latence de transmission des alertes de sécurité.

Mots-clés : réseaux véhiculaires, usagers vulnérables de la route, multi-armed bandit, ε -greedy, UCB, V2V, V2I, sélection de mode de communication, ITS-G5, IEEE 802.11p.

Table des matières

1	Introduction	4
1.1	Contexte et motivation	4
1.2	Problématique	4
1.3	Contributions	5
1.4	Organisation du rapport	5
2	État de l'Art	6
2.1	Communications V2X et standardisation	6
2.2	Protection des usagers de la route vulnérables	6
2.3	Apprentissage par renforcement dans les réseaux véhiculaires	7
2.4	Synthèse et positionnement	8
3	Scénario et Formulation du Problème	8
3.1	Description du scénario	8
3.2	Modèle de communication	9
3.3	Formulation du problème de sélection	10
4	Méthode Proposée : Multi-Armed Bandit	10
4.1	Rappel sur le cadre MAB	10
4.2	Algorithme ε -Greedy	11
4.3	Algorithme UCB (<i>Upper Confidence Bound</i>)	11
4.4	Comparaison théorique	12
5	Implémentation	13
5.1	Architecture du simulateur	13
5.2	Modélisation des entités	13
5.3	Paramétrage de la simulation	14
5.4	Extraits de code	14
6	Résultats	15

6.1	Métriques de simulation	15
6.2	Comparaison des politiques MAB	16
6.3	Influence de la priorité des URV	16
6.4	Décision finale des algorithmes	16
7	Discussion	17
7.1	Analyse des performances des algorithmes MAB	17
7.2	Limites et extensions	18
8	Conclusion	18

1 Introduction

1.1 Contexte et motivation

Les réseaux véhiculaires (VANETs) et, plus généralement, les communications V2X (*Vehicle-to-Everything*) représentent un pilier central des systèmes de transport intelligent (ITS) de nouvelle génération. L'émergence des véhicules connectés et autonomes a profondément transformé les exigences en matière de communication : les véhicules ne se contentent plus d'être des entités passives mais deviennent des nœuds actifs capables d'échanger des données de façon continue avec leur environnement.

Parmi les applications les plus critiques figure la protection des **usagers de la route vulnérables** (URV), une catégorie englobant les piétons, les cyclistes, les motocyclistes et tout utilisateur non protégé par une carrosserie métallique. Selon les données de l'Union Européenne, ces usagers représentent plus de 47% des victimes de la route, malgré leur part relativement faible dans les flux de circulation. La remontée périodique de données de localisation GPS par les URV, combinée aux mécanismes d'alerte V2X, offre une fenêtre d'opportunité pour détecter et prévenir des collisions potentielles.

Cette remontée d'informations peut être traitée à différents niveaux :

- **Au niveau du véhicule**, via des communications directes V2V (*Vehicle-to-Vehicle*) standardisées par IEEE 802.11p / ITS-G5 ;
- **Au niveau de l'infrastructure**, via des unités de bord de route (RSU – *RoadSide Units*) qui peuvent agréger, filtrer et redistribuer les informations à tous les véhicules dans leur portée (V2I) ;
- **Au niveau du edge cloud**, sur des serveurs déployés en bordure de route, capables d'exécuter des algorithmes d'intelligence artificielle pour analyser la situation et déclencher des alertes contextuelles.

La question se pose alors : *quel mode de communication choisir dans un contexte donné pour minimiser la latence et garantir la livraison fiable d'une alerte critique ?*

1.2 Problématique

Les réseaux véhiculaires se caractérisent par leur haute mobilité, leur densité variable, et une topologie en perpétuelle évolution. Dans ce contexte, les approches de sélection statique du mode de communication (V2V ou V2I) s'avèrent insuffisantes. En effet :

- Dans des zones denses (carrefours, intersections), les communications V2V peuvent être perturbées par un fort encombrement du canal radio ;

-
- Dans des zones peu denses ou hors de portée des RSUs, les communications V2I peuvent ne pas être disponibles ;
 - La qualité de signal, la charge du réseau et les conditions de mobilité varient rapidement et de façon imprévisible.

Face à cette incertitude inhérente, nous proposons d’adopter une approche d’apprentissage par renforcement légère et efficace : le cadre des **Multi-Armed Bandits (MAB)**. Cette approche permet d’apprendre en ligne la meilleure stratégie de communication sans nécessiter de modèle complet de l’environnement, en équilibrant exploration et exploitation des canaux disponibles.

1.3 Contributions

Les contributions de ce projet sont les suivantes :

1. Formulation du problème de sélection du mode de communication V2V/V2I comme un problème de Multi-Armed Bandit ;
2. Mise en œuvre et comparaison de deux algorithmes MAB : ϵ -greedy et UCB ;
3. Conception d’une simulation en Python modélisant des scénarios de communication entre URV et véhicules, avec différents profils de priorité ;
4. Analyse des performances des deux algorithmes selon les critères de délai, taux de perte et charge réseau ;
5. Discussion sur la scalabilité et les perspectives d’intégration dans un cadre normatif ETSI ITS-G5.

1.4 Organisation du rapport

Le reste de ce rapport est organisé comme suit. La Section 2 présente l’état de l’art sur les communications V2X, la protection des URV et les approches MAB dans les réseaux sans fil. La Section 3 détaille le scénario d’application et la formulation du problème. La Section 4 décrit en détail l’approche MAB proposée. La Section 5 présente l’implémentation. Les Sections 6 et 7 analysent et discutent les résultats. La Section 8 conclut le rapport.

2 État de l'Art

2.1 Communications V2X et standardisation

Les communications V2X couvrent quatre types d'interactions : V2V (véhicule à véhicule), V2I (véhicule à infrastructure), V2P (véhicule à piéton) et V2N (véhicule à réseau). Deux familles technologiques se distinguent actuellement :

DSRC / IEEE 802.11p / ITS-G5. Le standard DSRC (*Dedicated Short-Range Communications*) et sa déclinaison européenne ITS-G5 reposent sur une extension de la norme Wi-Fi IEEE 802.11a, opérant dans la bande des 5,9 GHz. Ce standard offre une latence très faible (de l'ordre de quelques millisecondes) et une portée typique de 300 à 1000 m, ce qui le rend particulièrement adapté aux applications de sécurité routière en temps réel [1]. L'ETSI a standardisé la génération de messages CAM (*Cooperative Awareness Message*) à une fréquence de 1 à 10 Hz selon la cinématique du véhicule.

C-V2X / 5G NR-V2X. Le C-V2X (*Cellular V2X*), introduit par le 3GPP dans les releases 14 et suivantes, s'appuie sur les réseaux cellulaires LTE et 5G pour offrir une couverture plus large et un débit plus élevé. Le 5G NR-V2X permet en particulier une communication en mode *sidelink* (PC5), analogue au V2V, et un mode infrastructure via le réseau cellulaire.

2.2 Protection des usagers de la route vulnérables

La protection des URV fait l'objet d'une attention croissante dans la communauté de recherche V2X. Les approches se divisent en plusieurs catégories.

Systèmes basés sur GPS et GNSS. La remontée périodique de la position GPS d'un URV permet de calculer sa trajectoire estimée et de détecter une intersection dangereuse avec celle d'un véhicule. Des travaux comme [9] ont étendu le format CAM aux équipements portables des URV, permettant de transmettre leur localisation à des intervalles réguliers.

Détection par capteurs embarqués. Les systèmes ADAS (caméras, LiDAR, radar) permettent de détecter les URV dans le champ de vision des véhicules. Cependant, ces systèmes sont limités par la portée des capteurs et les obstructions physiques.

Perception coopérative. Les approches de perception coopérative, telles que les CPM (*Collective Perception Messages*) standardisés par l'ETSI, permettent aux véhicules de partager leurs détections locales pour construire une représentation collective de l'environnement. Bouriga et al. [2] ont récemment proposé un cadre MAB profond pour filtrer les CAMs pertinents au niveau des RSUs, réduisant la consommation de bande passante de 88% par rapport à une diffusion naïve.

Alertes inter-RSU. Un axe peu exploré consiste à exploiter les communications inter-RSU pour relayer les informations relatives aux URV d'une zone couverte à une autre. Wang et al. [3] ont proposé InterCoop, un mécanisme de perception coopérative exploitant les interactions spatio-temporelles pour sélectionner les données les plus pertinentes à partager entre véhicules du réseau.

2.3 Apprentissage par renforcement dans les réseaux véhiculaires

L'apprentissage par renforcement (RL) a été largement étudié pour résoudre des problèmes d'optimisation dans les réseaux véhiculaires dynamiques.

Q-learning et DQN. Des travaux comme [4] ont exploité le Q-learning pour optimiser les paramètres de génération de messages coopératifs, améliorant la sécurité des URV tout en minimisant la consommation énergétique. D'autres travaux ont utilisé des réseaux de neurones profonds (DQN) pour le placement de fonctions réseau virtuelles dans des contextes au-delà de la 5G [?].

Multi-Armed Bandits dans les réseaux sans fil. Le cadre MAB a été appliqué avec succès à de nombreux problèmes dans les réseaux sans fil. Dans le contexte V2X, Hashima et al. [5] ont proposé un algorithme basé sur le *Thompson Sampling* pour la sélection opportuniste de bandes fréquentielles dans des systèmes V2X multi-bandes. Ce travail démontre l'efficacité des approches MAB pour les décisions en temps réel sans modèle de l'environnement.

Le MAB contextuel a également été exploré pour la sélection de faisceau dans les communications V2I mmWave [6], où il a permis de doubler le temps de maintien des connexions par rapport aux approches basées sur le SNR. Boukhalfa et al. [8] ont benchmarké différents algorithmes RL pour le handover vertical dans des réseaux hybrides véhiculaires.

MAB pour la sélection de mode de communication. À notre connaissance, l'application directe des MAB au problème de sélection binaire V2V/V2I pour la protection

des URV reste un sujet peu exploré. Le travail fondateur de Woodroffe [11] sur les bandits à un bras avec variable concomitante, et les extensions multi-bras de [12], fournissent les bases théoriques de notre approche. Dans les réseaux V2X, Baccour et al. [7] ont formulé la gestion du risque d'accident comme un problème MAB contextuel, montrant que l'agent peut apprendre à évaluer le risque et adapter son comportement de transmission en conséquence.

2.4 Synthèse et positionnement

Le Tableau 1 synthétise les principaux travaux connexes et positionne notre contribution. Si des travaux ont appliqué les MAB aux réseaux V2X pour la sélection de bande, de faisceau ou la gestion du handover, aucun ne traite le problème spécifique de la sélection adaptative V2V/V2I pour la protection des usagers vulnérables, en intégrant à la fois les contraintes de priorité des URV et les métriques réseau multi-critères.

TABLE 1 – Comparaison des travaux connexes

Travaux	Contexte V2X	MAB	URV	V2V/V2I	Multi-critères	RSU
Bouriga et al. [2]	✓	✓	–	V2I seul	✓	✓
Hashima et al. [5]	✓	✓	–	Multi-bande	✓	✓
C-MAB V2I [6]	✓	✓	–	V2I seul	–	–
Baccour et al. [7]	✓	✓	–	V2V seul	–	–
Zoghلامي et al. [4]	✓	–	✓	V2X	–	–
Notre travail	✓	✓	✓	V2V + V2I	✓	✓

3 Scénario et Formulation du Problème

3.1 Description du scénario

Nous considérons un environnement urbain dans lequel circulent trois types d'entités :

- **Les piétons** (*Pedestrian*) : usagers les plus vulnérables, priorité maximale (priorité = 1) ;
- **Les motocyclistes** (*Motorcycle*) : priorité intermédiaire (priorité = 2) ;
- **Les véhicules automobiles** (*Car*) : priorité la plus basse parmi les usagers (priorité = 3).

Chaque entité est modélisée par un objet **User** dont les attributs incluent l'identifiant, le protocole de communication, la portée radio, la capacité de traitement et la priorité. Des infrastructures (RSUs) sont également déployées et offrent une capacité de traitement supérieure.

La Figure 1 illustre le scénario considéré :




FIGURE 1 – Scénario de communication URV-véhicule : mode V2V direct (rouge) et mode V2I via RSU (bleu)

Deux modes de communication sont disponibles :

1. **Mode V2V** : communication directe entre l'URV et le(s) véhicule(s) à proximité, via IEEE 802.11p. Ce mode est disponible uniquement si le destinataire se trouve dans la portée radio de l'émetteur.
2. **Mode V2I** : l'URV envoie son message à la RSU la plus proche, qui le redistribue à l'ensemble des véhicules dans sa zone de couverture. Ce mode offre une couverture plus large mais peut introduire une latence supplémentaire en cas de charge réseau élevée.

3.2 Modèle de communication

Chaque protocole de communication est caractérisé par les paramètres suivants :

- N : charge réseau courante (*network load*) $\in [0, 1]$;
- P_l : taux de perte de paquets (*packet loss rate*) ;
- P_s : taux de succès de transmission (*transmission success rate*) ;
- τ : délai de transmission de base.

Pour le mode V2V, le protocole est configuré avec un taux de succès de $P_s^{V2V} = 0,6$ (reflétant les interférences et la mobilité), tandis que le mode V2I bénéficie d'un $P_s^{V2I} = 0,9$ (canal de backhaul plus stable).

Le délai de transmission total pour un message m entre un émetteur i et un récepteur j à distance d_{ij} est modélisé par :

$$\tau_{ij}(m) = \tau_0 + \alpha \cdot d_{ij} + \Delta_q(m) \quad (1)$$

où τ_0 est le délai de base, α un facteur de propagation, et $\Delta_q(m)$ le délai de file d'attente accumulé par le message m .

3.3 Formulation du problème de sélection

Objectif. Soit $\mathcal{M} = \{\text{V2V}, \text{V2I}\}$ l'ensemble des modes disponibles. À chaque instant t , un agent de décision sélectionne un mode $a_t \in \mathcal{M}$ pour transmettre une alerte de sécurité. L'objectif est de maximiser la récompense cumulée sur un horizon T :

$$\max_{a_1, \dots, a_T} \sum_{t=1}^T \mathbb{E}[r_t(a_t)] \quad (2)$$

Récompense. La récompense $r_t(a_t)$ est une combinaison pondérée des métriques inverses, capturant la qualité de la transmission :

$$r_t(a_t) = \frac{w_\tau}{\tau_t} + \frac{w_l}{P_{l,t}} + \frac{w_N}{N_t} \quad (3)$$

où w_τ, w_l, w_N sont des poids reflétant l'importance relative de chaque critère (Tableau 2).

TABLE 2 – Pondération des critères dans la fonction de récompense

Critère	Symbole	Poids
Délai de transmission	w_τ	1,0
Taux de perte de paquets	w_l	1,0
Charge réseau	w_N	0,2

Ce problème correspond à un MAB classique à 2 bras (V2V et V2I) avec des récompenses stochastiques, que nous étendons à un MAB multi-critères en décomposant chaque bras en trois sous-critères.

4 Méthode Proposée : Multi-Armed Bandit

4.1 Rappel sur le cadre MAB

Le problème du *Multi-Armed Bandit* (MAB), formalisé dès le début du XX^e siècle, modélise les décisions séquentielles sous incertitude. Un agent dispose de K bras (actions) et, à chaque round t , il sélectionne un bras $a_t \in \{1, \dots, K\}$ et reçoit une récompense stochastique $r_t \sim P_{a_t}$ de distribution inconnue P_k avec espérance μ_k .

L'objectif est de maximiser la récompense cumulée, ou de manière équivalente de minimiser le *regret cumulatif* :

$$\mathcal{R}(T) = T \cdot \mu^* - \sum_{t=1}^T \mathbb{E}[r_t] \quad \text{avec} \quad \mu^* = \max_k \mu_k \quad (4)$$

4.2 Algorithme ε -Greedy

L'algorithme ε -greedy est l'une des solutions les plus simples et les plus robustes au problème d'exploration-exploitation. À chaque round t :

- Avec probabilité ε : sélectionner un bras aléatoire (**exploration**) ;
- Avec probabilité $1-\varepsilon$: sélectionner le bras avec la valeur empirique maximale (**exploitation**).

La mise à jour incrémentale de la valeur estimée d'un bras k est :

$$\hat{\mu}_k(n) = \hat{\mu}_k(n-1) + \frac{1}{n} (r - \hat{\mu}_k(n-1)) \quad (5)$$

où n est le nombre de fois où le bras k a été sélectionné.

L'Algorithme 1 décrit la politique ε -greedy pour notre problème de sélection V2V/V2I.

Algorithm 1 ε -Greedy pour la sélection V2V/V2I

```

1: Entrée :  $\varepsilon \in (0, 1)$ , métriques V2V et V2I
2: Init :  $\hat{\mu}_k \leftarrow 0$ ,  $n_k \leftarrow 0$ ,  $k \in \{\text{V2V}, \text{V2I}\}$ 
3: Calculer les récompenses initiales  $r_{\text{V2V}}, r_{\text{V2I}}$  depuis les métriques simulées
4: Mettre à jour  $\hat{\mu}_k$  pour chaque critère de V2V et V2I
5: for chaque round  $t = 1, \dots, T$  do
6:   if Uniforme(0, 1) <  $\varepsilon$  then
7:      $a_t \leftarrow$  bras aléatoire ▷ Exploration
8:   else
9:      $a_t \leftarrow \arg \max_k \hat{\mu}_k$  ▷ Exploitation
10:  end if
11:  Transmettre l'alerte via le mode  $a_t$ 
12:  Observer la récompense  $r_t$ 
13:   $n_{a_t} \leftarrow n_{a_t} + 1$ 
14:   $\hat{\mu}_{a_t} \leftarrow \hat{\mu}_{a_t} + \frac{1}{n_{a_t}} (r_t - \hat{\mu}_{a_t})$ 
15: end for
16: Retour : mode sélectionné  $a^* = \arg \max_k \hat{\mu}_k$ 

```

4.3 Algorithme UCB (*Upper Confidence Bound*)

L'algorithme UCB [10], proposé par Auer, Cesa-Bianchi et Fischer, offre une garantie théorique de regret en $O(\log T)$. Il sélectionne le bras qui maximise une borne de confiance

supérieure sur la récompense estimée :

$$a_t = \arg \max_k \left(\hat{\mu}_k + \sqrt{\frac{2 \ln N_t}{n_k}} \right) \quad (6)$$

où $N_t = \sum_k n_k$ est le nombre total de rounds et n_k le nombre de sélections du bras k . Le terme $\sqrt{2 \ln N_t / n_k}$ représente un bonus d'exploration qui favorise les bras moins essayés.

Une propriété importante de l'UCB est qu'il garantit que chaque bras est d'abord essayé au moins une fois avant de commencer à exploiter (condition d'initialisation : si $n_k = 0$, sélectionner le bras k immédiatement).

L'Algorithme 2 présente la politique UCB adaptée à notre problème.

Algorithm 2 UCB pour la sélection V2V/V2I

```

1: Entrée : métriques V2V et V2I
2: Init :  $\hat{\mu}_k \leftarrow 0, n_k \leftarrow 0$ 
3: for  $k \in \{\text{V2V}, \text{V2I}\}$  do
4:   if  $n_k = 0$  then
5:     sélectionner et observer le bras  $k$ 
6:   end if
7: end for
8: Mettre à jour  $\hat{\mu}_k$  avec les récompenses observées
9: for chaque round  $t$  do
10:    $N_t \leftarrow \sum_k n_k$ 
11:   for  $k \in \{\text{V2V}, \text{V2I}\}$  do
12:      $\text{UCB}_k \leftarrow \hat{\mu}_k + \sqrt{2 \ln N_t / n_k}$ 
13:   end for
14:    $a_t \leftarrow \arg \max_k \text{UCB}_k$ 
15:   Observer  $r_t$ , mettre à jour  $\hat{\mu}_{a_t}$ 
16: end for

```

4.4 Comparaison théorique

Le Tableau 3 compare les deux algorithmes sur des critères théoriques et pratiques.

TABLE 3 – Comparaison théorique des algorithmes MAB

Critère	ε -Greedy	UCB
Regret cumulatif	$O(T)$	$O(\log T)$
Paramètres	ε (réglage manuel)	Aucun
Garanties théoriques	Faibles	Fortes
Adaptabilité	Faible (fixe)	Bonne (dynamique)
Complexité	$O(K)$	$O(K)$
Convergence	Lente (bruit)	Plus rapide
Robustesse au bruit	Bonne	Moyenne

5 Implémentation

5.1 Architecture du simulateur

Le simulateur est développé en Python et se compose de quatre modules principaux :

1. `simu.py` : génère les données de simulation en modélisant les entités (usagers, infrastructure), les protocoles, les files d'attente de messages et les métriques réseau ;
2. `MAB_epsilon.py` : implémente la politique ε -greedy et détermine le mode de communication optimal pour chaque paire métrique (V2V, V2I) ;
3. `MAB_UCB.py` : implémente la politique UCB pour la même tâche ;
4. `simulation_metrics.csv` : stocke les métriques produites par `simu.py` et consommées par les algorithmes MAB.

La Figure 2 décrit le flux de données entre ces modules.




FIGURE 2 – Architecture du système : flux entre les modules

5.2 Modélisation des entités

Classe User. La classe `User` modélise les usagers de la route. Elle gère :

- Une file d'attente de messages pondérée par la priorité combinée (priorité utilisateur + priorité message) ;
- La vérification de la portée avant transmission (`within_range`) ;
- La condition de non-congestion : la transmission est bloquée si $N > 0,8$;
- La mobilité simulée par une marche aléatoire discrète.

Classe Infrastructure. La RSU dispose d'une capacité de traitement supérieure (800 unités vs. 100–400 pour les usagers) et gère les messages entrants sans vérification de portée (modèle de couverture globale).

Classe Metrics. La classe `Metrics` accumule les mesures de performance :

- Délai total de transmission (τ_{total}) et de file d'attente ;
- Nombre de messages transmis avec succès et nombre perdus ;
- Charge réseau cumulée.

Le délai moyen, le taux de perte et la charge moyenne sont exportés vers le fichier CSV à la fin de chaque simulation.

5.3 Paramétrage de la simulation

TABLE 4 – Paramètres de la simulation

Paramètre	Description	Valeur
Nombre d'utilisateurs	Piétons, motos, voitures	3 de chaque
Nombre de RSUs	Infrastructures déployées	9
Protocole V2V	IEEE 802.11p	$P_s = 0,6$
Protocole V2I	IEEE 802.11p (infra)	$P_s = 0,9$
Délai de base τ_0	—	10 ms
Facteur distance α	—	10 ms/unité
Charge réseau N	Valeur aléatoire	$\sim U(0, 1)$
Pas de simulation	—	10 rounds
Taux d'exploration ε	ε -greedy	0,1

5.4 Extraits de code

Le Listing 1 présente la classe `EpsilonGreedy` et le calcul de la récompense dans notre implémentation.

Listing 1 – Implémentation de l'algorithme ε -greedy

```

1 class EpsilonGreedy:
2     def __init__(self, num_arms, epsilon):
3         self.num_arms = num_arms
4         self.epsilon = epsilon
5         self.counts = [0] * num_arms
6         self.values = [0.] * num_arms
7
8     def select_arm(self):
9         if np.random.random() < self.epsilon:
10             return np.random.randint(self.num_arms) # Exploration
11         else:
12             return np.argmax(self.values) # Exploitation

```

```

13
14 def update(self, chosen_arm, reward):
15     self.counts[chosen_arm] += 1
16     n = self.counts[chosen_arm]
17     value = self.values[chosen_arm]
18     # Mise a jour incrementale de la moyenne
19     new_value = ((n-1)/float(n)) * value + (1/float(n)) * reward
20     self.values[chosen_arm] = new_value
21
22 # Calcul des recompenses (inverses des metriques)
23 delay_weight, loss_weight, load_weight = 1.0, 1.0, 0.2
24 v2v_reward = delay_weight/v2v_delay + loss_weight/v2v_loss + \
25             load_weight/v2v_load
26 v2i_reward = delay_weight/v2i_delay + loss_weight/v2i_loss + \
27             load_weight/v2i_load

```

6 Résultats

6.1 Métriques de simulation

Les données produites par le simulateur reflètent les deux modes de communication dans des conditions réseau stochastiques. Le Tableau 5 présente des métriques typiques observées lors d'une exécution de simulation.

TABLE 5 – Métriques simulées pour V2V et V2I

Mode	Délai moyen (s)	Taux de perte	Charge réseau
V2V	0,032	0,40	0,62
V2I	0,021	0,10	0,47

Ces valeurs illustrent l'avantage général du mode V2I dans ce scénario : délai plus faible (meilleure fiabilité du canal backhaul), taux de perte réduit (moins d'interférences), et charge réseau moindre.

6.2 Comparaison des politiques MAB




FIGURE 3 – Comparaison de la récompense cumulée : UCB vs ϵ -greedy




FIGURE 4 – Comparaison par critère entre les modes V2V et V2I

6.3 Influence de la priorité des URV

L'intégration de la priorité des utilisateurs dans la gestion des files d'attente permet de garantir que les messages des piétons (priorité = 1) sont systématiquement traités avant ceux des motocyclistes (priorité = 2) et des automobiles (priorité = 3). La Figure 5 illustre l'ordre de transmission dans une file partagée.




FIGURE 5 – Ordre de traitement par priorité dans la file de messages

6.4 Décision finale des algorithmes

Dans les conditions simulées, les deux algorithmes convergent vers le mode **V2I** comme mode de communication préféré pour les alertes de sécurité des URV, en raison d'un

meilleur taux de succès et d'un délai plus faible. La Figure 6 résume le score global de chaque mode selon chaque algorithme.




FIGURE 6 – Score final des deux modes selon les algorithmes MAB

7 Discussion

7.1 Analyse des performances des algorithmes MAB

Les deux algorithmes MAB démontrent leur capacité à sélectionner le mode de communication le plus performant sans connaissance a priori des distributions de récompense. Quelques observations méritent d'être soulignées.

ϵ -greedy. La politique ϵ -greedy ($\epsilon = 0,1$) converge rapidement vers le mode V2I dans ce scénario. Son principal avantage est la simplicité d'implémentation et la robustesse aux variations stochastiques des métriques. Cependant, avec un ϵ fixe, l'agent continue d'explorer de façon aléatoire même après convergence, ce qui peut entraîner des décisions sous-optimales à long terme. Une variante ϵ -décroissant permettrait d'améliorer ce comportement.

UCB. L'algorithme UCB garantit théoriquement un regret logarithmique $O(\log T)$ et offre une exploration plus systématique que l' ϵ -greedy. La borne de confiance supérieure assure que les bras peu explorés bénéficient d'un bonus croissant, évitant l'abandon prématuré d'options potentiellement meilleures. En pratique, UCB converge légèrement plus vite vers la décision optimale et atteint un score légèrement supérieur.

7.2 Limites et extensions

Nombre limité d’observations. La simulation actuelle repose sur un nombre relativement faible de rounds (10 pas de temps). Une évaluation sur des séquences plus longues permettrait de mieux quantifier le regret et la convergence.

MAB contextuel. L’approche actuelle est non contextuelle : elle ne prend pas en compte l’état courant de l’environnement (densité, météo, type de zone). Une extension naturelle consiste à adopter un MAB contextuel, comme proposé dans [2] pour le filtrage de CAMs au niveau des RSUs, où le vecteur de contexte intègre la cinématique des véhicules et la topologie routière.

Apprentissage en ligne distribué. Dans un scénario multi-RSU, chaque RSU pourrait exécuter son propre agent MAB et partager les estimations de récompense avec ses voisins, réalisant ainsi un apprentissage fédéré ou coopératif. Cette perspective est explorée dans les travaux futurs de [2].

Conformité ETSI ITS-G5. Le simulateur implémente le protocole IEEE 802.11p, compatible avec ITS-G5. Pour une intégration complète dans un système ITS normalisé, les décisions MAB pourraient être encapsulées dans la couche de gestion (ITS-S Management Entity) et interagir avec le service de génération de CAMs défini par l’ETSI [1].

Données réelles. Les métriques actuelles sont générées par simulation. L’utilisation de traces réelles (collectées sur des bancs d’essai V2X ou via des plateformes de test comme ETSI CTI) renforcerait la validité externe des résultats.

8 Conclusion

Ce rapport a présenté un mécanisme de sélection adaptative du mode de communication V2V/V2I pour la protection des usagers de la route vulnérables, fondé sur l’approche Multi-Armed Bandit. Deux algorithmes ont été mis en œuvre – ϵ -greedy et UCB – et évalués sur un simulateur Python modélisant des scénarios réalistes d’interaction entre URV et véhicules.

Les principaux apports de ce travail sont :

1. La formulation du problème de sélection de mode de communication comme un MAB à deux bras avec récompenses multi-critères (délai, taux de perte, charge réseau) ;

-
2. La démonstration que l'algorithme UCB converge plus efficacement que l' ϵ -greedy grâce à sa borne de confiance supérieure, tout en maintenant une exploration systématique ;
 3. L'intégration d'un système de priorité basé sur le type d'URV, garantissant que les alertes des piétons sont traitées en premier ;
 4. La validation de la capacité des deux algorithmes à sélectionner automatiquement le mode V2I dans les conditions simulées, conformément aux intuitions réseau.

Les perspectives ouvertes par ce travail incluent l'extension vers un MAB contextuel exploitant l'état spatio-temporel des URV et des véhicules, l'apprentissage distribué multi-RSU, et la validation sur des données de terrain. Ces axes rejoignent directement les problématiques abordées dans les travaux récents sur la perception coopérative dans les réseaux véhiculaires [2].

Références

- [1] ETSI, "EN 302 637-2 - V1.4.1 - Intelligent Transport Systems (ITS) ; Vehicular communications ; basic set of applications ; part 2 : specification of cooperative awareness basic service," 2019.
- [2] A. Bouriga, R. Kacimi, and R. Dhaou, "Deep Reinforcement Learning-Powered Extended Vehicular Cooperative Perception," *International Wireless Communications & Mobile Computing Conference (IWCMC)*, IEEE, Shanghai, China, Jun. 2026.
- [3] W. Wang, H. Xu, and G. Tan, "InterCoop : Spatio-Temporal Interaction Aware Cooperative Perception for Networked Vehicles," *2024 IEEE Int. Conf. Robotics and Automation (ICRA)*, Yokohama, Japan, 2024, pp. 14443–14449.
- [4] C. Zoghliami, R. Kacimi, and R. Dhaou, "Leveraging RL for Efficient Collection of Perception Messages in Vehicular Networks," *2024 Global Information Infrastructure and Networking Symposium (GIIS)*, Dubai, UAE, 2024.
- [5] S. Hashima, M. M. Fouda, K. Hatano, E. Takimoto, and Z. M. Fadlullah, "Multi-Armed Bandit-Aided Near-Optimal Over-The-Air Updates in Multi-Band V2X Systems," *5th Int. Conf. Computer Communication and the Internet (ICCCI)*, 2023, pp. 179–184.
- [6] "Context-Aware Beam Selection for IRS-Assisted mmWave V2I Communications," *MDPI Sensors / PMC*, 2024.
- [7] E. Baccour, A. Erbad, A. Mohamed, M. Guizani, and R. Hamila, "Reinforcement Learning for Accident Risk-Adaptive V2X Networking," *arXiv :2004.02379*, 2020.
- [8] F. Boukhalfa, R. Alami, M. Achab, E. Moulines, M. Bennis, and T. Lestable, "Deep Reinforcement Learning Algorithms for Hybrid V2X Communication : A Benchmar-

-
- king Study,” *2024 IEEE Int. Conf. Communications Workshops (ICC Workshops)*, Denver, CO, USA, 2024, pp. 1956–1961.
- [9] V. Wolff, “Enhancing vulnerable road user awareness of intelligent transport systems through relay and aggregation of collective perception messages with road side units,” Science and Technology Publications, 2023.
- [10] P. Auer, N. Cesa-Bianchi, and P. Fischer, “Finite-time analysis of the multiarmed bandit problem,” *Machine Learning*, vol. 47, no. 2–3, pp. 235–256, 2002.
- [11] M. Woodroffe, “A one-armed bandit problem with a concomitant variable,” *Journal of the American Statistical Association*, vol. 74, no. 368, pp. 799–806, 1979.
- [12] V. Anantharam, P. Varaiya, and J. Walrand, “Asymptotically efficient allocation rules for the multiarmed bandit problem with multiple plays,” *IEEE Transactions on Automatic Control*, vol. 32, no. 11, pp. 968–982, 2003.
- [13] B. L. Nguyen, D. T. Ngo, N. H. Tran, M. N. Dao, and H. L. Vu, “Dynamic V2I/V2V Cooperative Scheme for Connectivity and Throughput Enhancement,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 23, no. 2, pp. 1236–1246, Feb. 2022.